CAN YOU DETECT FRAUD FROM CUSTOMER TRANSACTIONS?

Informe final

PRESENTADO POR:

AURA LUZ MORENO DÍAZ,

INGENIERÍA INDUSTRIAL

PRESENTADO A:

RAÚL RAMOS POLLAN

UNIVERSIDAD DE ANTIOQUIA

FACULTAD DE INGENIERIA

2023

PREPROCESAMIENTO DEL DATASET

El presente trabajo hace parte de la tercera entrega para el curso Inteligencia Artificial para las Ciencias y la Ingeniería. Para esto, debemos dar un testimonio acerca de las dificultades y los aciertos que tuvimos luego de ver los videos del curso e investigar en fuentes alternativas para el desarrollo hasta la fecha de nuestro trabajo predictivo.

La mayor parte del tiempo fue invertido en conocer como traer los datos desde Kaggle. Se intentó inicialmente cargar los datos desde google drive pero no era funcional. Se intentó desde un hosting alternativo haciendo el llamado desde colab, pero tampoco funcionó, luego de leer toda la documentación disponible, pudimos crear la API KEY y traer los datos directamente desde la competencia de Kaggle y que funcionara correctamente.

Hemos decidido trabajar con el dataset de la empresa VESTA en la cual se trata de detectar cuando una transacción es fraudulenta. La variable crítica es IsFraud que finalmente se convierte en un booleano que toma valores True o False

El Dataset está compuesto por 4 archivos .CSV (tablas) así:

sample_submission

test_identity

test_transaction

train_identity

train_transaction

De estos, teníamos que elegir con cual trabajaríamos, sin embargo, desde la misma competencia de Kaggle nos indicaban que ambas tablas estaban relacionadas por la clave primaria del código de la transacción, por lo que sabemos desde ya que para el desarrollo final de este trabajo debemos incluir a ambas: **Identity** and **Transactions**.

ANALISIS DE LOS DATOS

TABLA IDENTITY

Las variables en esta tabla son información de identidad:

información de conexión de red (IP, ISP, Proxy, etc.) y firma digital (UA/ navegador/OS/versión, etc.) asociada con las transacciones.

Son recopilados por el sistema de protección contra fraudes de Vesta y los socios de seguridad digital.

(Los nombres de los campos están enmascarados y no se proporcionará el diccionario por pares para la protección de la privacidad y el acuerdo del contrato)

- TransactionID
- id_12 - id_38
- DeviceType
- DeviceInfo

TABLA TRANSACTIONS:

- TransactionDT: timedelta de una fecha y hora de referencia determinada (no una marca de tiempo real). timedelta de una fecha y hora de referencia dada (no una marca de tiempo real). El primer valor de TransactionDT es 86400, que corresponde a la cantidad de segundos en un día (60 * 60 * 24 = 86400), así que creo que la unidad es segundos. Usando esto, sabemos que los datos abarcan 6 meses, ya que el valor máximo es 15811131, que correspondería al día 183"
- TransactionAMT: monto del pago de la transacción en USD
- ProductCD: código de producto, el producto para cada transacción
- card1 - card6: información de la tarjeta de pago, como tipo de tarjeta, categoría de tarjeta, banco emisor, país, etc.
- dirección: dirección addr1 como región de facturación, addr2 como país de facturación
- distancia: distancias entre (no limitadas) la dirección de facturación, la dirección postal, el código postal, la dirección IP, el área telefónica, etc
- P_ y (R__) emaildomain: dominio de correo electrónico del comprador y del destinatario
- C1-C14: conteo, como cuántas direcciones se encuentran asociadas con la tarjeta de pago, etc. El significado real está enmascarado.
- D1-D15: timedelta, como días entre transacciones anteriores, etc.
- M1-M9: coincidencia, como nombres en la tarjeta y dirección, etc.
- Vxxx: características completas diseñadas por Vesta, que incluyen clasificación, conteo y otras relaciones de entidad.

Características categóricas:

ProductCD

card1 - card6

addr1, addr2

P_emaildomain

R_emaildomain

M1 - M9

La tabla más grande corresponde a la de transacciones y es la que tiene información más relevante, por ejemplo, el monto de la transacción la cual podríamos usar para saber el monto total de transacciones que son fraudulentas, cruzándola con la tabla identidad, podríamos conocer desde

que navegador se realizan, o cual franquicia es la más vulnerada (Amex, Visa, Mastercard, etc) por monto o por cantidad de repeticiones.

También podríamos determinar si los fraudes se realizaron más desde celulares o desde computadores y desde qué sistema operativo se realizaron.

Cuáles son los usuarios más vulnerados según el correo electrónico que usen, por ejemplo gmail, outlook o correos con dominios privados.

PROCESAMIENTO DE DATOS

Se realiza un preprocesamiento de datos identificando las columnas de ambas tablas. Para esto, se determinan cuáles son susceptibles para nuestras métricas.

Tenemos inicialmente dfi para el Data Frame de Identity

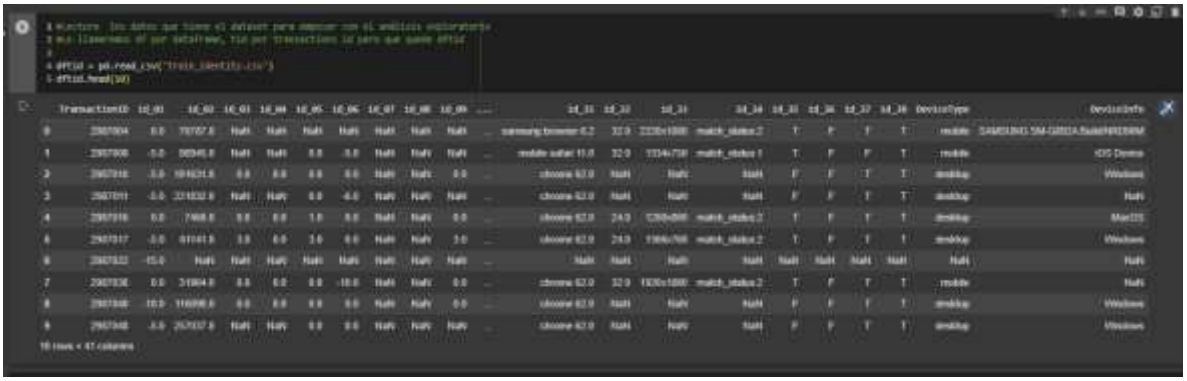

Para lo cual tenemos valores NaN con un porcentaje del 35.6%

```
Existen valores NaN: True
Total de valores NaN: 2104107
El porcentaje de valores NaN: 35.6%
```

Creamos un dftid_sinNan para filtrar todos los datos nulos y tener un dataframe más limpio.

Ahora cambiamos algunas cosas de Identidad así:

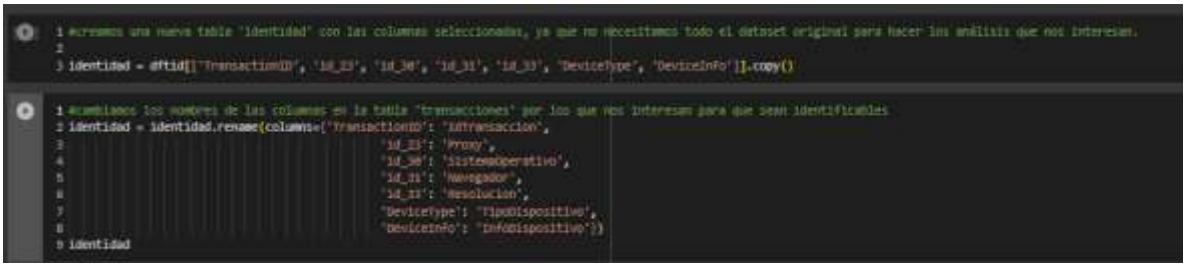

```
#hacemos los cambios pertinentes para Proxy
identidad['Proxy'] = identidad['Proxy'].replace(['IP_PROXY:TRANSPARENT'], 'Transparent')
identidad['Proxy'] = identidad['Proxy'].replace(['IP_PROXY:ANONYMOUS'], 'Anonymous')
identidad['Proxy'] = identidad['Proxy'].replace(['IP_PROXY:HIDDEN'], 'Hidden')
```

Más adelante podría interesarnos si los fraudes se realizan desde equipos detrás de proxies, con cual sistema operativo, desde que dispositivo, por lo cual son datos que se quedan a pesar de que son variables categóricas que luego se convertirán a numéricas.

Al tratar de hacer lo mismo con la tabla transacciones, nos damos cuenta que más del 41% son datos nulos y que no siempre coinciden con la clave primaria que es el ID de la transacción, por lo que decidimos dejarla tal cual está.

```
#Debemos verificar cuántos valores nulos tenemos en la tabla, para esto hacemos el chequeo asi:
check_for_any_nan= dfttr.isna().any().any()#Vamos a encontrar cuantos valores NaN existen en el dataframe
total_nan_values = dfttr.isna().sum().sum()#Vamos a sumar el total de valores NaN presentes en el dataframe
fil ,col = dfttr.shape
num_datos = fil*col
print("Existen valores NaN: "+str(check_for_any_nan))
print("Total de valores NaN: "+str(total_nan_values))
#print("El porcentaje de valores NaN: " +str((total_nan_values*100)/num_datos) + "%")
print("El porcentaje de valores NaN: {:.1f}%".format(round((total_nan_values*100)/num_datos, 1)))
```

```
Existen valores NaN: True
Total de valores NaN: 95566686
El porcentaje de valores NaN: 41.1%
```

Hacemos tratamiento de los valores faltantes:

```
transacciones.isnull().sum() #Columnas con valores nulos
```

```
IdTransaccion       0
EsFraude            0
LineaDeTiempo       0
MontoTransaccion    0
Franquicia          0
TipoTarjeta         0
DominioCompra       0
dtype: int64
```

```
[25] transacciones['DominioCompra'] = transacciones['DominioCompra'].fillna('Sin Información')
     transacciones['Franquicia'] = transacciones['Franquicia'].fillna('Sin Información')
     transacciones['TipoTarjeta'] = transacciones['TipoTarjeta'].fillna('Sin Información')
```

Rellenamos los nulos de df

```
[ ]  1 df.shape  #Tenemos 144.233 transacciones con 13 columnas que nos informan varias cosas sobre la transacción

     (144233, 13)

[28]  1 null_counts = df.isnull().sum()
      2 print(null_counts)
      3

     IdTransaccion           0
     Proxy              139064
     SistemaOperativo    66668
     Navegador            3951
     Resolucion          70944
     TipoDispositivo      3423
     InfoDispositivo     25567
     EsFraude                0
     LineaDeTiempo           0
     MontoTransaccion        0
     Franquicia              0
     TipoTarjeta             0
     DominioCompra           0
     dtype: int64

      1 columns_to_fillna = ['Proxy', 'Navegador', 'Resolucion', 'TipoDispositivo', 'InfoDispositivo']
      2 for column in columns_to_fillna:
      3     df[column] = df[column].fillna('Sin Información')
```

ANALISIS DE LOS DATOS

Se analiza la variable objetivo IsFraud

```
[ ]  1 #Distribución de la variable objetivo
     2 sns.distplot(df['isFraud'])

<Axes: xlabel='isFraud', ylabel='Density'>
```

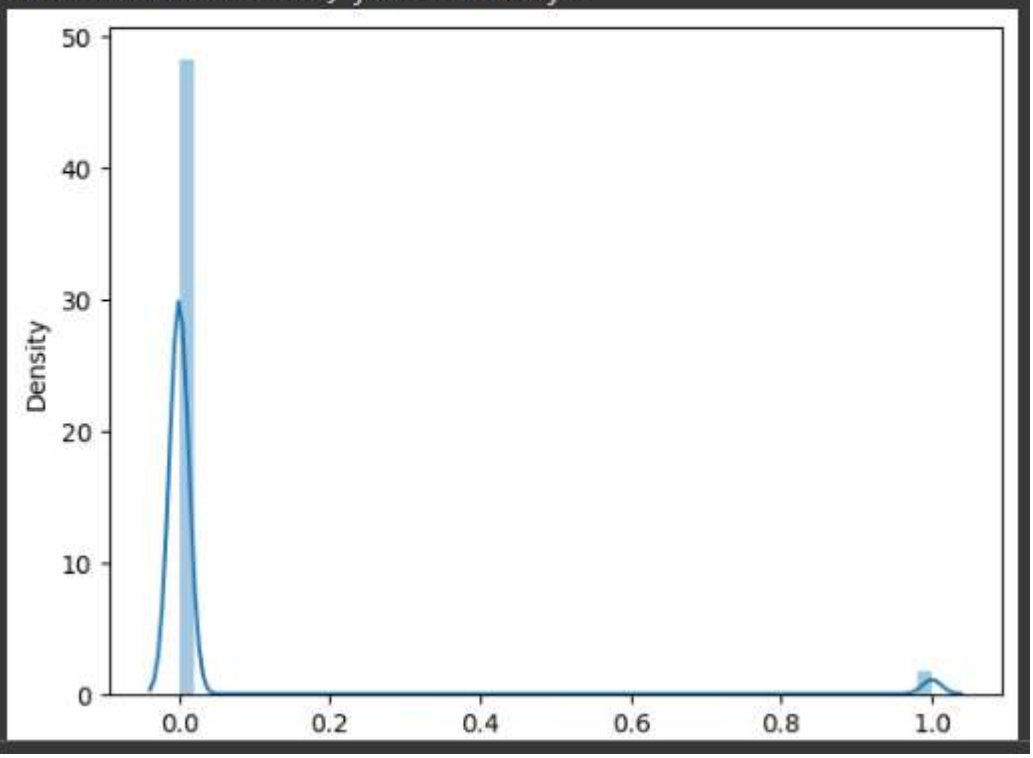

Y se mide su sesgo, donde se podría inferir que es una prueba de bondad y ajuste en la que la distribución obedece a una distribución normal.

```
[ ]  1 #Ahora mediremos el sesgo de nuestra variable objetivo
     2 print('Skewness de la variable objetivo {:.1f}%'.format(round((df['isFraud'].skew()),1)))

    Skewness de la variable objetivo 5.1%
```

Con esto podemos ver que nuestra variable objetivo EsFraude está desbalanceada
lo cual tiene toda la lógica ya que el porcentaje de fraudes siempre va a ser mucho menor de los que si lo son.

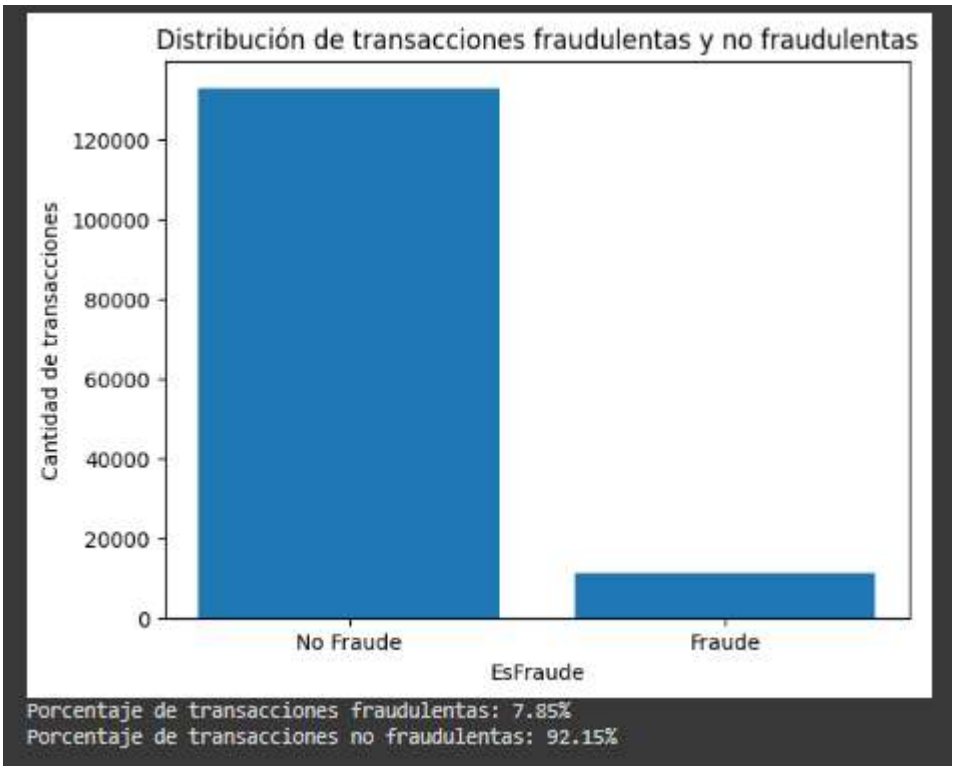

Se realizan algunas aproximaciones para enteder un poco más los datos:

```
1 df.describe()
2
```

	IdTransaccion	EsFraude	LineaDeTiempo	MontoTransaccion
count	1.442330e+05	144233.000000	1.442330e+05	144233.000000
mean	3.236329e+06	0.078470	6.166958e+06	83.554533
std	1.788496e+05	0.268911	4.807714e+06	99.850258
min	2.987004e+06	0.000000	8.650600e+04	0.251000
25%	3.077142e+06	0.000000	1.885289e+06	25.453000
50%	3.198818e+06	0.000000	4.913738e+06	50.000000
75%	3.392923e+06	0.000000	1.025794e+07	100.000000
max	3.577534e+06	1.000000	1.581103e+07	1800.000000

Aquí se puede observar la distribución de los datos y su desbalance en las variables numéricas

La distribución de transacciones por franquicia:

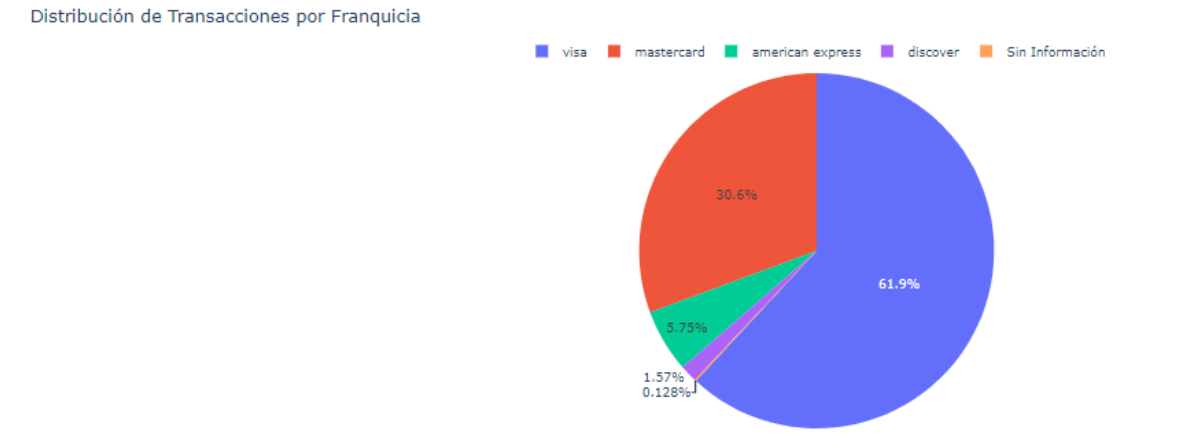

Por ejemplo desde que dispostivo (movil o escritorio) se realizan más fraudes:

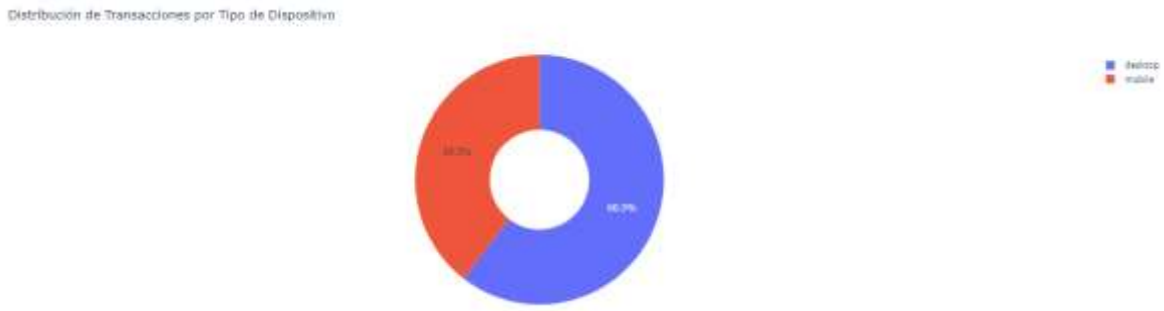

Desde qué sistema operativo se hacen más fraudes:

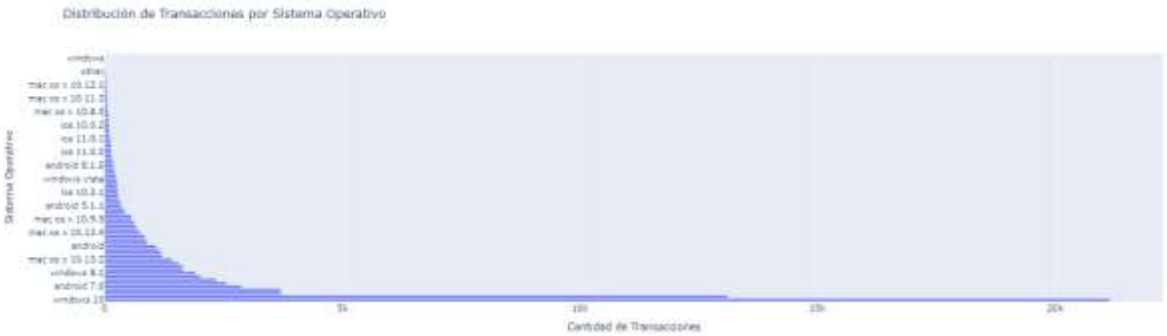

Transacciones por tipo de dispositivo

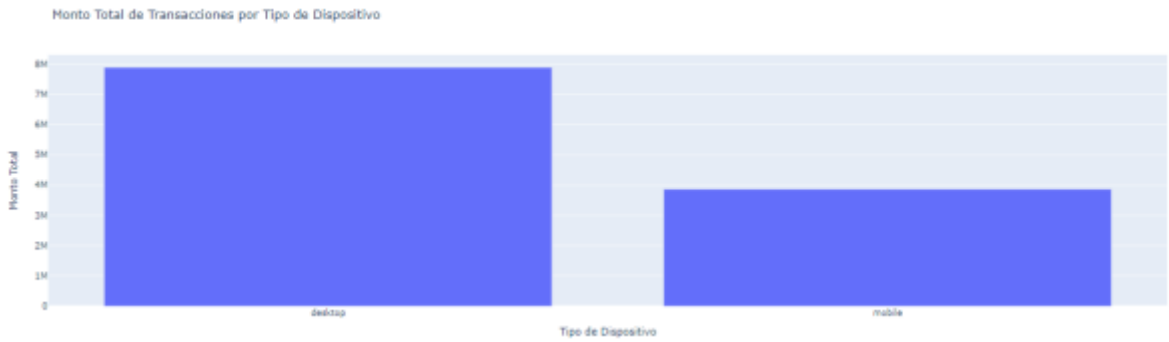

La distribución de las variables categóricas

```
[ ]  1 #Distribución de las variables categóricas
     2 df['Franquicia'].value_counts().plot(kind='bar')
     3 plt.xlabel('Franquicia')
     4 plt.ylabel('Frecuencia')
     5 plt.title('Distribución de la Franquicia')
     6 plt.show()
     7
```

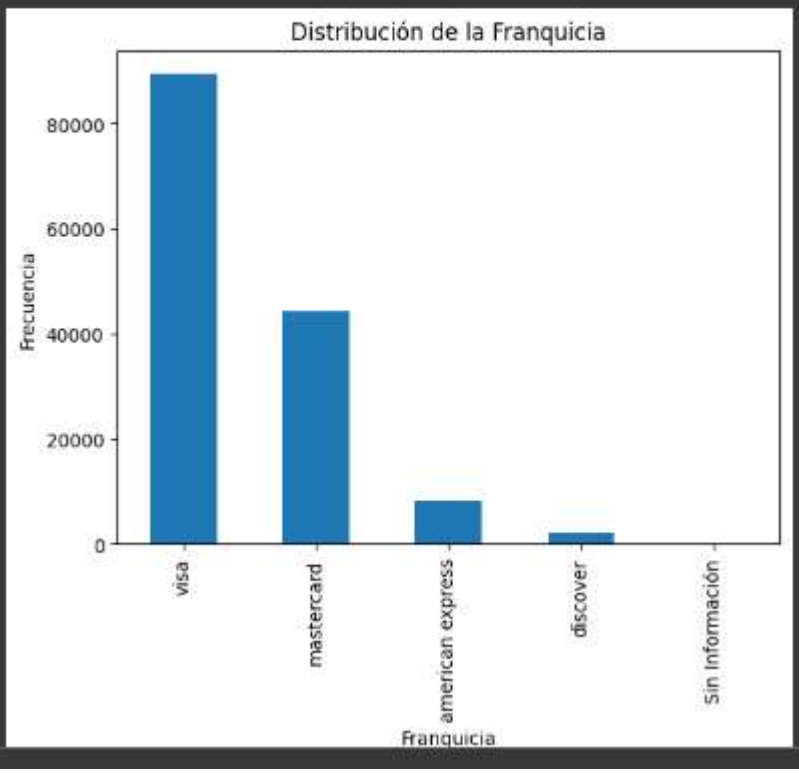

Cantidad de fraudes por franquicia

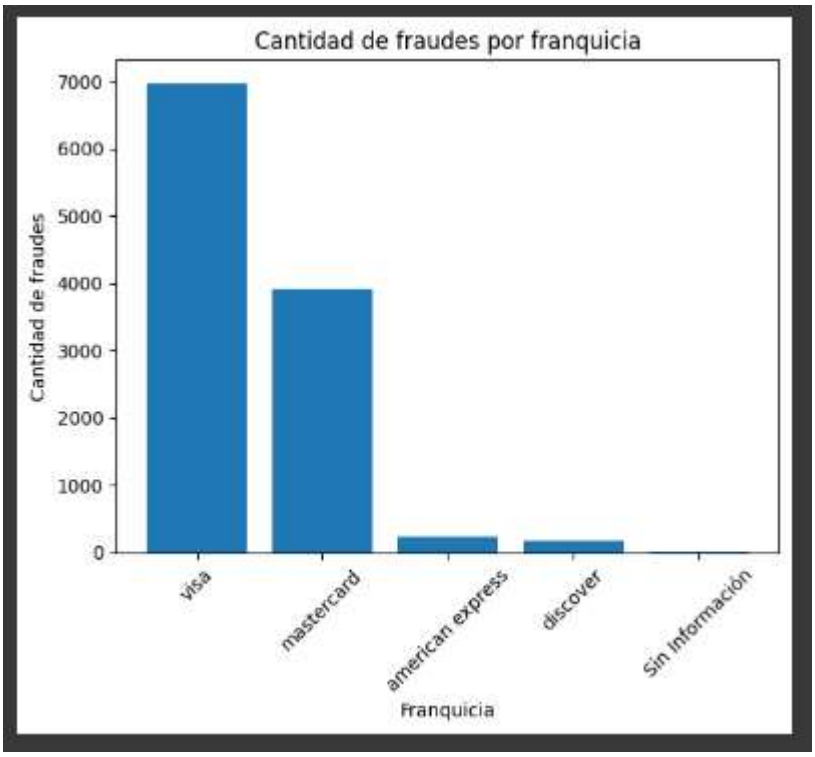

METRICAS DE EVALUACIÒN

Esta es nuestra matriz de correlación:

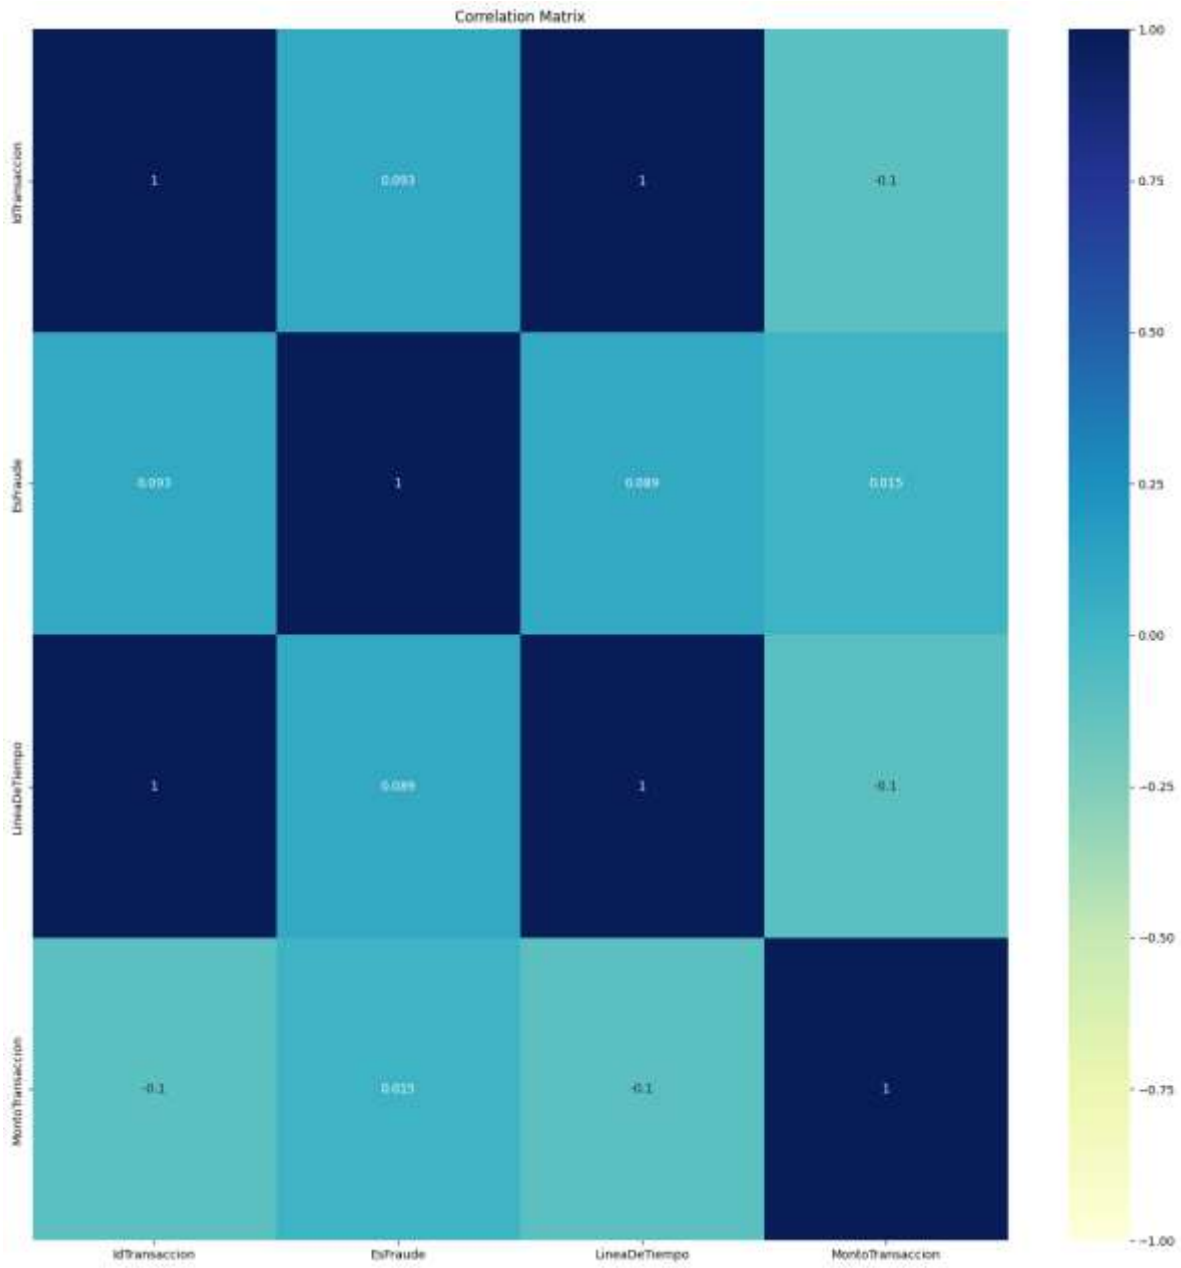

Y la distribución de las variables numéricas

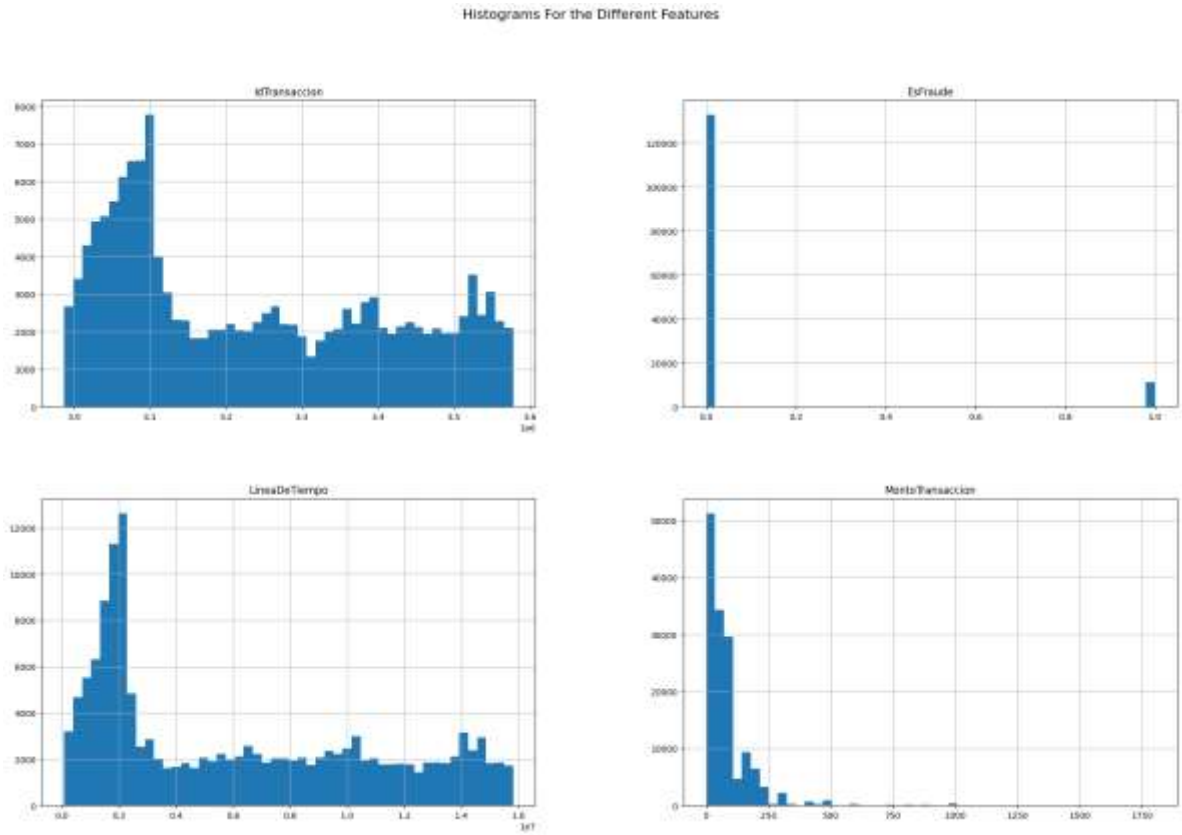

Nuestra matriz de correlaciones

```
1 #Correlaciones de las variables con la variable objetivo
2 target_corr_df = pd.DataFrame(corr_matrix["EsFraude"].sort_values(ascending=False))
3 target_corr_df
```

	EsFraude
EsFraude	1.000000
IdTransaccion	0.092935
LineaDeTiempo	0.089427
MontoTransaccion	0.015380

La relación entre el monto de la transacción y la franquicia

```
sns.scatterplot(x='MontoTransaccion', y='Franquicia', data=df)
plt.xlabel('Monto de Transacción')
plt.ylabel('Franquicia')
plt.title('Relación entre Monto de Transacción y Franquicia')
plt.show()
```

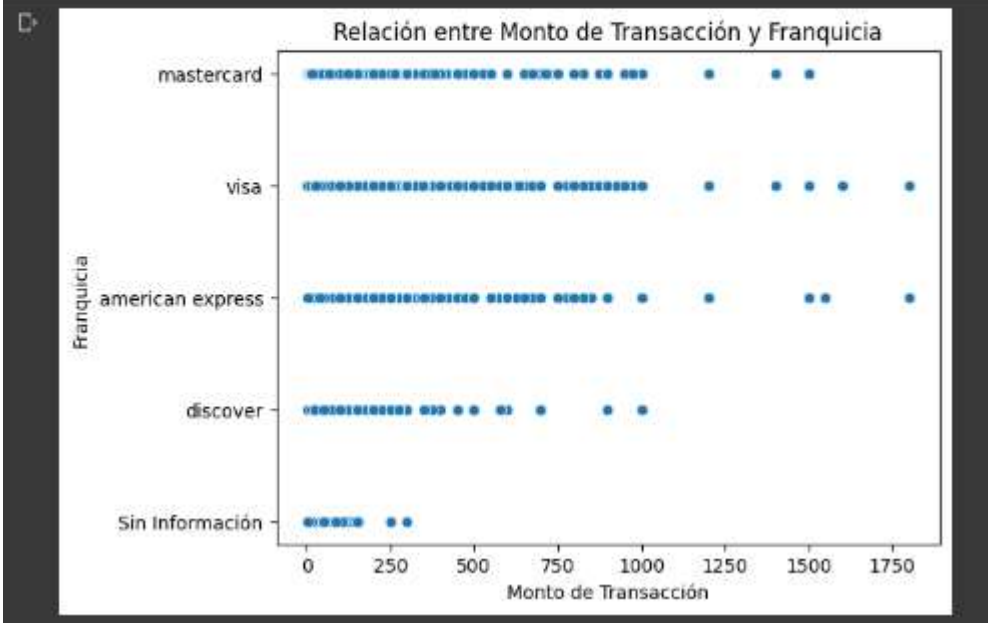

Los cuantiles teóricos

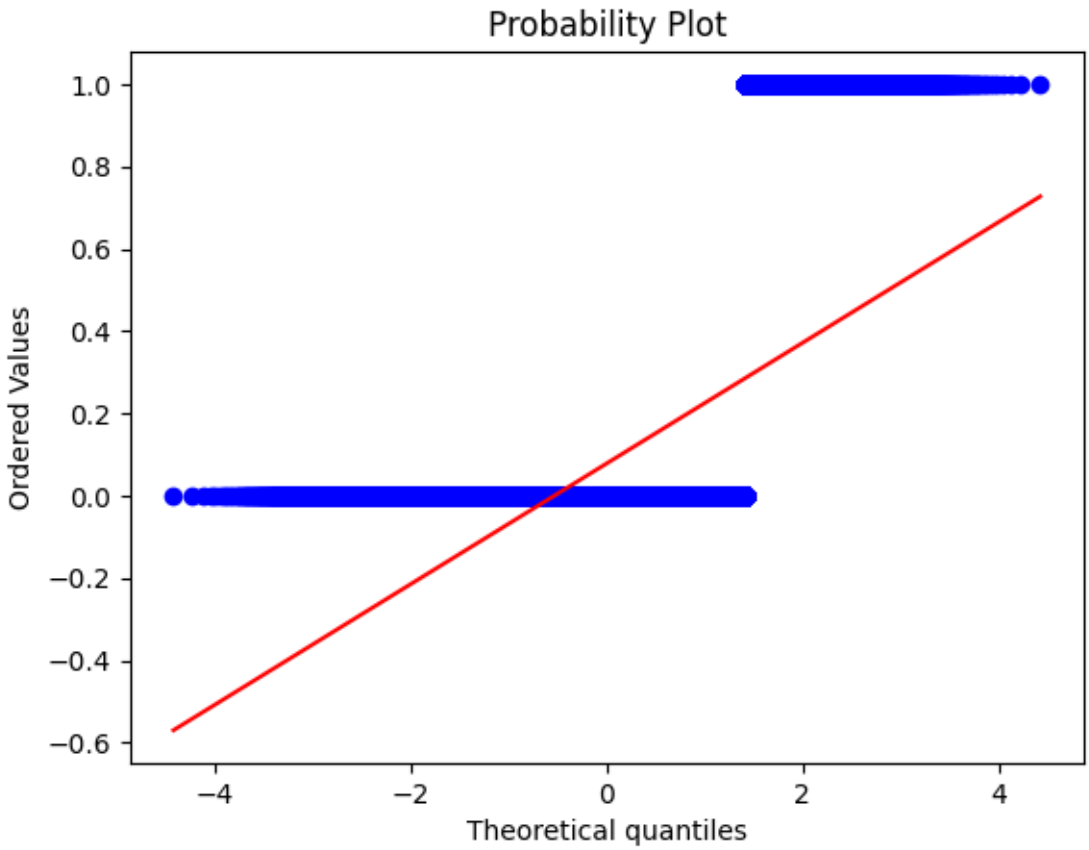

Y nuestra curva ROC que no tiene coherencia:

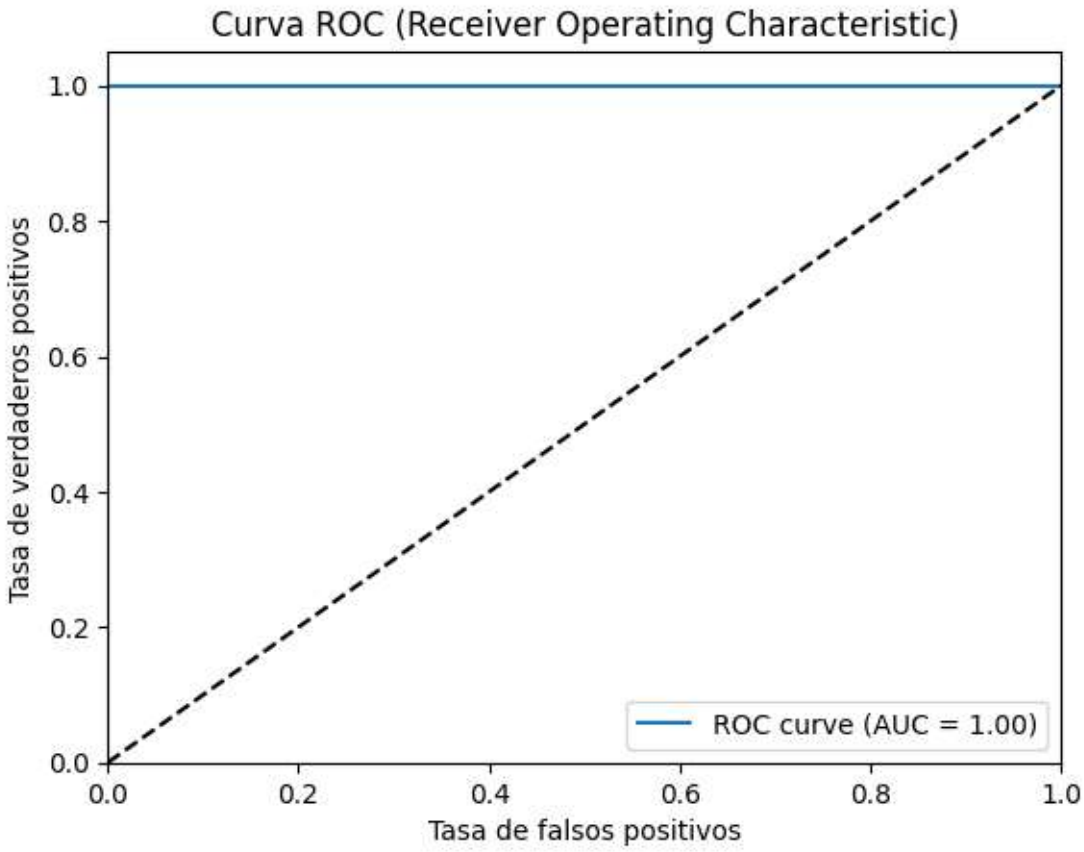


```
1 from sklearn.metrics import classification_report
2
3 print(classification_report(y_test, y_pred))
4
```

```
              precision    recall  f1-score   support

           0       0.92      1.00      0.96     26587
           1       0.00      0.00      0.00      2260

    accuracy                           0.92     28847
   macro avg       0.46      0.50      0.48     28847
weighted avg       0.85      0.92      0.88     28847
```

Obteniendo resultados muy bajos.

Para entrenar un algoritmo de machine learning necesitamos lo siguiente:

1. **Recopilación y preparación de los datos:** Estos ya venían en la competencia de Kaggle aunque con información muy sesgada ya que al tratarse de datos bancarios nos hacían

falta elementos de peso para determinar cuando se hace fraude o no. Por ejemplo, el país, región o ciudad desde donde se hacía la transacción y la hora.

2. **División de los datos.** Estos ya venían en train y test que son los datos que nos proporciona Kaggle. Trabajamos todo el tiempo con train.
3. **Selección del algoritmo de machine learning:** Árboles de decisión. Vector machine, redes neuronales, algoritmo de regresión
4. **Entrenamiento del modelo:** Se usa train para verificar.
5. **Ajuste de hiperparámetros**
6. **Evaluación del modelo:** Se usa el conjunto de prueba para comprobar que funciona.Aqui se usa accuracy, recall, F1, RMSLE.
7. **Ajuste y mejora**

Métricas para análisis del modelo:

Clasificación:

Exactitud (Accuracy): Es la proporción de predicciones correctas sobre el total de predicciones.

Precisión (Precision): Es la proporción de verdaderos positivos sobre la suma de verdaderos positivos y falsos positivos. Mide la precisión de las predicciones positivas.

Recall (Sensibilidad o Exhaustividad): Es la proporción de verdaderos positivos sobre la suma de verdaderos positivos y falsos negativos. Mide la capacidad del modelo para encontrar todos los casos positivos.

Puntuación F1 (F1 Score): Es la media armónica de precisión y recall. Proporciona un equilibrio entre ambos indicadores.

Curva ROC y Área bajo la curva (AUC-ROC): Mide el desempeño del modelo a través de la tasa de verdaderos positivos y falsos positivos a diferentes umbrales de clasificación.

Regresión:

Error cuadrático medio (Mean Squared Error, MSE): Calcula la diferencia cuadrática promedio entre los valores reales y las predicciones.

Raíz del error cuadrático medio (Root Mean Squared Error, RMSE): Es la raíz cuadrada del MSE y proporciona una medida del error promedio en la misma escala que la variable de destino.

Error absoluto medio (Mean Absolute Error, MAE): Calcula la diferencia promedio en valor absoluto entre los valores reales y las predicciones.

Coeficiente de determinación (R-squared): Mide la proporción de la varianza en la variable objetivo que puede explicarse por el modelo. Un valor de 1 indica una predicción perfecta.

Dado que el problema es la detección de fraudes en transacciones, y asumiendo que se trata de un problema de clasificación binaria, un algoritmo adecuado para este caso es el Random Forest. Los Random Forest son un conjunto de árboles de decisión que combinan las predicciones individuales de cada árbol para obtener una predicción final. Algunas razones por las cuales un Random Forest sería una buena elección para este problema son:

Capacidad para manejar variables numéricas y categóricas: Los Random Forest pueden manejar tanto variables numéricas como categóricas, lo cual es útil cuando se tienen diferentes tipos de características en los datos.

Robustez frente al sobreajuste: Los Random Forest tienden a ser menos propensos al sobreajuste en comparación con un solo árbol de decisión. Esto se debe a que utilizan muestras aleatorias de los datos de entrenamiento y características aleatorias en cada árbol, lo que reduce la correlación entre los árboles y mejora la generalización del modelo.

Importancia de las características: Los Random Forest proporcionan una medida de importancia de las características, lo que permite identificar qué características tienen mayor influencia en la detección de fraudes.

Capacidad de manejar conjuntos de datos grandes: Los Random Forest pueden manejar conjuntos de datos grandes de manera eficiente, lo que puede ser beneficioso si el conjunto de datos de transacciones es grande.

DIFICULTADES

Hemos encontrado que por ser un dataframe de datos bancarios, se vuelve información MUY sensible, haciendo que Vesta no comparta muchos de los datos que ellos usan para detectar fraude, limitando el dataset a solo algunos datos que permitan sacar conclusiones. Nos hubiera gustado datos más abiertos, por ejemplo de ubicación. Si la persona estaba en un lugar diferente a su ubicación normal. O desde que país se hacen más fraudes, pero esta información no está disponible.